# Miloš Veljanovski 1559

Projekat 1 - Sistemi za analizu velike količine podataka

# Korišćeni izvorni podaci

- Iskorišćen je <u>set podataka</u> o vožnji biciklama iz "oblasti zaliva" tj. San Francisko zaliva (uključujući Palo Alto i San Hoze)
- Dataset sadrži sledeće kolene podataka:
  - Vreme i datum početka i završetka vožnje
  - Podaci o početkoj stanici (ID, ime, geografska širina i dužina)
  - Podaci o završnoj stanici (ID, ime, geografska širina i dužina)
  - ID vožnje
  - Tip korisnika (vozača)
- Korišćeni su podaci za 2021. i 2022. godinu

# Samostalna python aplikacija koja koristi Spark biblioteku

## main.py

 Inicijalnom setu podataka sam izračunao i dodao sledeće kolone: vreme trajanja vožnje, pređena distanca (tačnije udaljenost početne i kranje stanice vazdušnom linijom) i srednja brzina

```
# Add ride duration column
timeDiff = (unix_timestamp('ended_at', 'yyyy-MM-dd HH:mm:ss') - unix_timestamp('started_at', 'yyyy-MM-dd HH:mm:ss'))
df = df.withColumn('duration', timeDiff)

# Add distance column
df = df.withColumn('distance', geodesic_udf(array('start_lat', 'start_lng'), array('end_lat', 'end_lng')))

# Add average speed column
df = df.withColumn('average_speed', col('distance')/col('duration'))
```

• Ulazne argumente aplikacije učitavam koristeći dotenv biblioteku

```
if __name__ == "__main__":
   spark = SparkSession.builder.appName('PySparkApp').getOrCreate()
   startTime = datetime.now()
   load_dotenv()
   SAN_JOSE_LATITUDE = float(os.getenv('SAN_JOSE_LATITUDE'))
   SAN_JOSE_LONGITUDE = float(os.getenv('SAN_JOSE_LONGITUDE'))
   SAN_FRANCISCO_LATITUDE = float(os.getenv('SAN_FRANCISCO_LATITUDE'))
   SAN_FRANCISCO_LONGITUDE = float(os.getenv('SAN_FRANCISCO_LONGITUDE'))
   YEAR_START = int(os.getenv('YEAR_START'))
   MONTH_START = int(os.getenv('MONTH_START'))
   DAY_START = int(os.getenv('DAY_START'))
   YEAR_END = int(os.getenv('YEAR_END'))
   MONTH_END = int(os.getenv('MONTH_END'))
   DAY_END = int(os.getenv('DAY_END'))
   FILE_DATA = os.getenv('FILE_DATA')
   HDFS_DATA = os.getenv('HDFS_DATA')
```

- U svrhu demonstracije, kroz aplikaciju sam realizovao 5 zadataka (task-ova) za smislenu obradu podataka
- Zadatak 1 prikazuje imena početne i krajnje stanice svih vožnji koje su počele u San Hoze-u (početne koordinate su južnije od 37.43749 i istočnije od -122.08746) i završile se u San Francisku (krajnje koordinate su severnije od 37.65876 i zapadnije od -122.36854)

```
# Task 1
task1 = df.select(df.start_station_name, df.end_station_name).filter((df.start_lat < SAN_JOSE_LATITUDE) &
        (df.start_lng > SAN_JOSE_LONGITUDE) & (df.end_lat > SAN_FRANCISCO_LATITUDE) & (df.end_lng < SAN_FRANCISCO_LONGITUDE)).collect()
output.append('Task 1:\n\n''Trips from San Jose to San Francisco:\n')
print('\nTrips from San Jose to San Francisco:\n')
for row in task1:
    print(str(row['start_station_name']) + ", " + str(row['end_station_name']))
    output.append(str(row['start_station_name']) + ", " + str(row['end_station_name']))</pre>
```

 Zadatak 2 prikazuje ukupan broj vožnji za svaki tip bicikle za dati vremenski period (od 01.06.2022. do 05.06.2022.)

 Zadatak 3 prikazuje prosečno trajanje vožnje za oba tipa korisnika

 Zadatak 4 prikazuje broj biciklista koji su završili vožnju na nekoj od stanica na Van Nes aveniji i srednja vremena trajanja tih vožnji

```
# Task 4
task4 = df.groupBy('end_station_name').agg(count('ride_id').alias('ride_count'), mean('duration').alias('mean_trip_time'))\
    .filter(col('end_station_name').like('%Van Ness Ave%'))\
    .sort(col('mean_trip_time').asc()).collect()
output.append('Task 4:\n')
for row in task4:
    task4_result = 'Number of bike rides that ended on the \'' + str(row.asDict()['end_station_name']) + '\' is '\
    + str(row.asDict()['ride_count']) + ' with mean time of ' + str(row.asDict()['mean_trip_time']) + ' seconds.'
    print(task4_result)
    output.append(task4_result)
```

 Zadatak 5 pronalazi rutu vožnje kod koje je standardna devijacija vremena vožnje bila najviša

Pokretanje aplikacije na kontejnerima imajući izvornu baywheels.csv datoteku sa podacima na HDFS-u

- Preuzeti docker-hadoop repozitorijum sa github-a: https://github.com/big-data-europe/docker-hadoop
- Otvoriti docker-compose.yml datoteku (trenutno sadrži instrukcije za pravljenje sledećih Hadoop servisa: namenode, datanode, resourcemanager, nodemanager1, historyserver)
- Ovoj mreži kontejnera dodati sledeće Spark servise:
  - spark-master:
     image: bde2020/spark-master:3.1.2-hadoop3.2
     container\_name: spark-master
     ports:
     "8080:8080"
     "7077:7077"
     environment:
     INIT\_DAEMON\_STEP=setup\_spark

```
• spark-worker-1:
   image: bde2020/spark-worker:3.1.2-hadoop3.2
     container_name: spark-worker-1
     depends_on:
      - spark-master
     ports:
      - "8081:8081"
     environment:
      - "SPARK_MASTER=spark://spark-master:7077"
• spark-worker-2:
   image: bde2020/spark-worker:3.1.2-hadoop3.2
     container_name: spark-worker-2
     depends_on:
      - spark-master
     ports:
      - "8082:8081"
     environment:
      - "SPARK_MASTER=spark://spark-master:7077"
```

Finalna verzija docker-compose.yml datoteke je dostupna na sledećem linku: <a href="https://github.com/Veljanovskii/bigdata-project-1/blob/main/docker-compose.yml">https://github.com/Veljanovskii/bigdata-project-1/blob/main/docker-compose.yml</a>

 Pokrenuti mrežu kontejnera pomoću docker compose up -d komande

- Zatim, potrebno je kopirati datoteku sa izvornim podacima na HDFS
  - Najpre na namenode pomoću:
    - docker cp baywheels.csv namenode:baywheels.csv
  - Pokrenuti namenode pomoću:
    - docker exec -it namenode bash
  - Opciono, napraviti odgovarajući direktorijum gde će datoteka biti smeštena:
    - hdfs dfs -mkdir -p /user/root/input
  - Smestiti izvornu datoteku u dati folder:
    - hdfs dfs -put baywheels.csv /user/root/input/baywheels.csv

Ovime je csv datoteka podignuta na HDFS i nalazi se na lokaciji: hdfs://namenode:9000/user/root/input/baywheels.csv

- Slično, možemo podići izvorni kod python skripte na sparkapp kontejner
  - Spark-app image pravimo na osnovu sledećeg Dockerfile-a komandom docker build --rm -t spark-app.
    - FROM bde2020/spark-python-template:3.1.2-hadoop3.2
    - RUN cd /app pip install -r requirements.txt
    - ENV SPARK\_APPLICATION\_PYTHON\_LOCATION /app/main.py
    - ENV SPARK\_APPLICATION\_ARGS /app/.env
  - Pokretanje pomoću: docker run --name spark-app --net dockerhadoop\_default -p 4040:4040 -d spark-app

- Doker kopiranje:
  - docker cp main.py spark-app:/bin
- Pokrenuti spark-app pomoću:
  - docker exec -it spark-app bash
- Pokrenuti skriptu pomoću:
  - /spark/bin/spark-submit --master spark://spark-master:7077 main.py

Ovime je aplikacija pokrenuta na klasteru Spark Docker kontejnera

Stanje i tok rada aplikacije se može pratiti na <a href="http://localhost:8080/">http://localhost:8080/</a>



## Spork Master at spark://a7ff0cf06a96:7077

URL: spark://a7ff0cf06a96:7077

Alive Workers: 2

Cores in use: 16 Total, 0 Used

Memory in use: 47.7 GiB Total, 0.0 B Used

Resources in use:

Applications: 0 Running, 14 Completed Drivers: 0 Running, 0 Completed

Status: ALIVE

#### → Workers (2)

Worker Id	Address	State	Cores	Memory	Resources
worker-20230212002055-172.19.0.8-35197	172.19.0.8:35197	ALIVE	8 (0 Used)	23.8 GiB (0.0 B Used)	
worker-20230212002055-172.19.0.9-33015	172.19.0.9:33015	ALIVE	8 (0 Used)	23.8 GiB (0.0 B Used)	

### **▼** Running Applications (0)

	utor Resources Per Executor	Submitted Time	User	State	Duration
--	-----------------------------	----------------	------	-------	----------

### **→** Completed Applications (14)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
app-20230212004511-0013	PySparkApp	16	1024.0 MiB		2023/02/12 00:45:11	root	FINISHED	52 s
app-20230212004408-0012	PySparkApp	16	1024.0 MiB		2023/02/12 00:44:08	root	FINISHED	50 s
app-20230212004250-0011	PySparkApp	16	1024.0 MiB		2023/02/12 00:42:50	root	FINISHED	52 s
app-20230212004102-0010	PySparkApp	16	1024.0 MiB		2023/02/12 00:41:02	root	FINISHED	56 s
app-20230212003959-0009	PySparkApp	16	1024.0 MiB		2023/02/12 00:39:59	root	FINISHED	53 s
app-20230212003842-0008	PySparkApp	16	1024.0 MiB		2023/02/12 00:38:42	root	FINISHED	53 s
app-20230212003232-0007	PySparkApp	16	1024.0 MiB		2023/02/12 00:32:32	root	FINISHED	59 s
app-20230212003129-0006	PySparkApp	16	1024.0 MiB		2023/02/12 00:31:29	root	FINISHED	52 s
app-20230212003019-0005	PySparkApp	16	1024.0 MiB		2023/02/12 00:30:19	root	FINISHED	51 s